



UNIVERSIDAD NACIONAL DE SAN JUAN

FACULTAD DE INGENIERÍA

TRABAJO FINAL DE GRADUACIÓN

Plantilla de L^AT_EX para los trabajos finales de Ingeniería Electrónica

Edwin BARRAGÁN

Pablo Daniel AGUADO

ASEORES:

Dr. Ing. Germán Alejandro GONZÁLEZ

Dr. Ing. Germán Emilio MAS

Dr. Ing. Fabricio «Carlos» EMDER

2018

UNIVERSIDAD NACIONAL DE SAN JUAN
FACULTAD DE INGENIERIA
Departamento de Electrónica y Automática

TRABAJO FINAL MUY INTERESANTE
Trabajo Final

Nombre Nombre APELLIDO
Autor

Dr. Nombre APELLIDO
Asesores

Ing. Nombre APELLIDO

En este trabajo se diseñó y creó un programa informático para la clasificación automática de almendras peladas a partir de imágenes de ellas, analizando diversas características de forma y de color. Para probarlo se construyó un prototipo de sistema de visión artificial con el cual se creó un conjunto de 564 imágenes de almendras y otros objetos. El conjunto de imágenes fue etiquetado manualmente en base a las normas de la Comisión Económica de las Naciones Unidas para Europa (UNECE) para el comercio de almendras. Los resultados del clasificador desarrollado son similares a los obtenidos con algoritmos de clasificación estándar, como máquinas de soporte vectorial o *Boosted Trees*. Los descriptores elegidos permiten clasificar binariamente el conjunto con una exactitud global de 93 %.

Agradezco a todos, por todo.

Dicho eso, expando mis agradecimientos a quienes de alguna u otra manera contribuyeron a este Trabajo Final y a todos los años de estudio que le preceden.

El autor

Índice general

1 Lecciones de la vida	1
1.1 Referidas a los alimentos	1
1.1.1 Burbujas quemadas de las galletas de agua	1
2 Introducción	7
2.1 Problemática y motivación	7
2.2 La almendra	8
2.3 Normas	9
2.4 Soluciones existentes	9
2.5 Propuesta	11
2.6 Herramientas y materiales	12
3 Resultados	13
3.1 Metodología de ajuste y evaluación	15
3.1.1 Evaluación	15
3.1.2 Métrica	16
3.1.3 Ajuste	16
3.2 Resultados	17
Referencias	20
Programas	20
Créditos de imágenes	21
A Organización de los archivos	22
B Uso de los programas	23

En El Principito de Antoine de Saint-Exupéry, el protagonista encuentra a un hombre de negocios que acumula estrellas con el único propósito de poder comprar más estrellas.

El Principito está perplejo. Solo posee una flor, que riega a diario, y tres volcanes que limpia cada semana.

«Es útil, pues, para mis volcanes y para mi flor que yo las posea», dijo el Principito, «pero tú, tú no eres nada útil para las estrellas...».

<http://custodians.online/spanish3.html>

1 Lecciones de la vida

Gracias al paquete `inputenc` (cargado como `\usepackage[utf8]{inputenc}`), podemos escribir en español sin ningún problema. Ejemplos: tíldes.

1.1 Referidas a los alimentos

1.1.1 Burbujas quemadas de las galletas de agua

Por qué son malas

Cómo sacarlas

Análisis de mercado

Traviata

Las galletas Traviata son de las preferidas por el mercado, especialmente para sopar en té negro dulce. Sin embargo, tal como se observa en la figura 1.1a¹, a veces tienen muchas burbujas quemadas. El nivel de quemazón no es estable, y el consumidor afortunado puede encontrar un paquete de galletas sin burbujas quemadas. Son las menos; normalmente uno encontrará unas como las que se ven en la figura² 1.1b. Esto es con `autoref`: Figura 1.1a, Figura 1.1b, y no está bueno por lo dicho en la nota 2.

En este párrafo uso el paquete `cleverref` para referenciar. Por ejemplo, hago referencia a la figura 1.1, o a la sección 1.1, o a las figuras 1.1a y 1.1b.

`Cleverref` también me permite referenciar números de página. Por ejemplo, puedo pedir que lean la página 1.

También puedo insertar los nombres de las referencias: lean la sección 1.1, Referidas a los alimentos.

¹Normalmente, `cref` es la opción preferible para citar, ya que automáticamente añade el tipo de referencia, y es mejor que `autoref` del paquete `hyperref`. Sin embargo, puede ser útil usar el tradicional `ref` en otros casos.

²En español los nombres de elementos comunes como «figura», «sección», «tabla», se escriben en con minúscula inicial. Escribirlos con mayúscula es un anglicismo, según la Fundéu BBVA via mail privado.



(a) Ejemplo 1.



(b) Ejemplo 2.

Figura 1.1: Estas son galletas Traviata con burbujas quemadas.



(a) Ejemplo 1.



(b) Ejemplo 2.



(c) Ejemplo 3.

Figura 1.2: Estas son galletas Traviata con burbujas quemadas.



(a) Ejemplo 1.



(b) Ejemplo 2.



(c) Ejemplo 3.



(d) Ejemplo 4.

Figura 1.3: Estas son galletas Traviata con burbujas quemadas.



(a) Ejemplo 1.



(b) Ejemplo 2.



(c) Ejemplo 3.



(d) Ejemplo 4.

Figura 1.4: Estas son galletas Traviata con burbujas quemadas.

Criollitas

Este es un párrafo de las Criollitas.

Mediatarde

Este es un párrafo de las Mediatarde.

Hogareñas Este párrafo referido a las galletas Hogareñas está hecho con \paragraph{} en lugar de \minisec{}. Es otra opción de encabezado menor. Probablemente sea mejor que minisec, para mantener uniformidad.

Y la tabla 1.1 es una tabla de ejemplo.

Acá un poco del uso de SIUnitx para el formato de números y unidades. 30 kg, 80 %, 2015, 40 000, 800 × 600 px, 640 × 480, 45°, 10 a 20 kg, 1, 2 y 3 m, 1 a 10 °C, 12,3 ± 0,2 kg. También funciona en modo matemático: 15 000 µg

Tabla 1.1: cultivos de almendra en Argentina en 2015. [1]

Provincia	Superficie cultivada [Ha]
Mendoza	2580
San Juan	572
La Rioja	498
Salta	189
Río Negro y Neuquén	170
Otras	200
Total	4209

Agrego por último unas ecuaciones de ejemplo. Se determinan a continuación la media circular y la desviación estándar circular, que se usaron como descriptores de color. [2]

Sea un conjunto de n ángulos a_1, a_2, \dots, a_n . Estos pueden interpretarse como n vectores \mathbf{v} de magnitud 1 y ángulos a_1, a_2, \dots, a_n respectivamente:

$$\mathbf{v}_n = 1 e^{j a_n} \quad (1.1)$$

Si se convierten a coordenadas cartesianas, se tiene:

$$\mathbf{v}_n = \cos(a_n) + j \sin(a_n) \quad (1.2)$$

Sumando los n vectores obtenemos el vector resultante \mathbf{a} :

$$\mathbf{a} = \sum_1^n \mathbf{v}_n = R e^{j \rho} \quad (1.3)$$

La **media circular** (o **ángulo medio** en este caso) es el ángulo ρ descripto por este vector resultante \mathbf{a} . La longitud media de los vectores \mathbf{v}_n se define como:

$$\bar{R} = \frac{R}{n} \quad (1.4)$$

Y la **desviación estándar circular** como:

$$S = \sqrt{\ln\left(\frac{1}{\bar{R}^2}\right)} = \sqrt{-2 \ln(\bar{R}^2)} \quad (1.5)$$

Un poco de código A continuación, un poco de código de Matlab, usando el paquete `listings`.³

Listing 1.1: Cálculo del vector de covarianza de dos señales.

```

1 function [ Rvw ] = vwcovar( v,w, maxlag )
2 %WCOCVAR [ Rvw ] = vwcovar( v,w, maxlag )
3 % Calcula la covarianza Rvw entre dos señales , v y w, hasta un retardo
4 % máximo maxlag. Las vectores v y w deben ser de la misma longitud; en
5 % caso contrario , se recortará el más largo .

```

³Ver también el paquete `minted`, se ve muy interesante.

```

6 Nv = length(v);
7 Nw = length(w);
8 if Nv ~= Nw
9 warning('Se recortará el vector más largo');
10 if Nv > Nw
11 v = v(1:Nw);
12 N = Nw;
13 else
14 w = w(1:Nv);
15 N = Nv;
16 end
17 else
18 N = Nv; % = Nw;
19 end
20
21
22 if maxlag > N-1
23 warning('maxlag debe ser menor a la longitud del vector más corto');
24 maxlag = N-1;
25 end
26
27 % Usamos, si es posible, 10 veces la cantidad de retardo deseada, para
28 % utilizar más datos y tener menos error. En caso contrario, todos los
29 % datos disponibles.
30 if (maxlag) > N-1
31 c = maxlag;
32 elseif (10*maxlag) > N-1
33 c = N-1;
34 else
35 c = 10*maxlag;
36 end
37
38 % Utilizamos funciones optimizadas de Matlab en lugar de hacer los
39 % cálculos
40 % con sumatorias. La normalización insesgada (unbiased) es la habitual y
41 % pedida en el ejercicio. Consiste en dividir los valores en N-t.
42 % http://www.mathworks.com/help/signal/ug/correlation-and-covariance.html
43 xc = xcov(v,w,c,'unbiased');
44 Rvw = xc(c+1:c+1+maxlag);
45

```

Y un poco más de código, pero esta vez en C++:

Swap values

```

#include <utility>
#include <string>

int main() {
    std::string s1 = "Hello";

```

```
std :: string s2 = "World";
using std :: swap;
swap(s1, s2);

}
```

2 Introducción

2.1 Problemática y motivación

La almendra es la fruta seca de mayor producción y consumo en el mundo. [3] Se comercializa con diversos grados de industrialización: con cáscara; pelada; blanqueada; en trozos; como harina; como aceite y como pasta, entre otros. El mercado mundial de las almendras está dominado en un 80% por dos principales productores: Estados Unidos y España. En 2015, nuestro país tenía más de 4000 hectáreas cultivadas (ver tabla 2.1), siendo Mendoza la provincia de mayor superficie cultivada, seguida por San Juan y La Rioja. En 2013 se importaron más de 1800 toneladas de almendras para el consumo local —desde Chile y Estados Unidos—, mientras que se exportaron 33 toneladas a España, Paraguay y Uruguay. [4]

Tabla 2.1: cultivos de almendra en Argentina en 2015. [1]

Provincia	Superficie cultivada [Ha]
Mendoza	2580
San Juan	572
La Rioja	498
Salta	189
Río Negro y Neuquén	170
Otras	200
Total	4209

El procesamiento mínimo para comercializar las almendras implica el descapotado y el pelado. El descapotado consiste en eliminar la cáscara externa o «capote» (exocarpio y mesocarpio del fruto); en el pelado se rompe la cáscara interna (endocarpio del fruto) para finalmente extraer la semilla. Este procesamiento es realizado mecánicamente por máquinas especializadas, pero puede provocar ligeros daños en algunos frutos. Posteriormente se realiza un proceso de clasificación o filtrado en el cual se eliminan restos de cáscaras, almendras dañadas y cualquier objeto extraño. Esta clasificación es habitualmente realizada mediante clasificadores ópticos, máquinas de alta tecnología y costo que mediante iluminadores, cámaras y eyectores de aire, separan los productos buenos de los malos y la basura.

En la región, y particularmente en la provincia de San Juan, la producción está centrada en pequeñas y medianas empresas agroindustriales. Hoy en día algunos productores optan por vender las almendras con cáscara; serán otros quienes les den, al pelarlas, mayor valor agregado. Otros productores sí realizan esa etapa de procesado, separando las almendras buenas de forma manual, lo cual requiere mano de obra especializada y muchas horas de trabajo; el promedio por operario es de entre 15 y 30 kg por jornada. La escasez de mano de obra especializada (debido a lo rutinario de la tarea) impacta en los

costos de producción, pero estos productores no pueden afrontar los costos de adquirir una máquina clasificadora óptica.

El Proyecto de Desarrollo Tecnológico y Social (PDTs) «Diseño e implementación de una estrategia de clasificación óptica de almendras para pequeños productores» es una iniciativa impulsada por la Universidad Nacional de San Juan (UNSJ) y la Secretaría de Ciencia, Tecnología e Innovación del Gobierno de San Juan (SECITI) que pretende, a largo plazo, desarrollar una clasificadora óptica de almendras destinada al sector MiPyME agroindustrial de la región del Nuevo Cuyo. [5] Para ello hay que diseñar, construir y probar todas las partes mecánicas, electrónicas y de software de la máquina, como así también los procesos que en ella se realizan y cómo se integran a los procesos existentes. Debe ser de bajo costo y ser al menos tan eficiente como un operario humano que clasifica manualmente.

Este trabajo es un pequeño aporte inicial a ese PDTs, y aborda el diseño e implementación de un sistema de visión artificial para la clasificación de almendras

2.2 La almendra

La almendra es el fruto (tipo drupa) del árbol llamado almendro (*Prunus dulcis* [Mill.] D.A. Webb). Una drupa es un fruto monospermo de mesocarpio carnoso, coriáceo o fibroso, que rodea a un endocarpio leñoso (carozo o hueso) con una sola semilla en su interior. Otras drupas son el durazno, la cereza, la aceituna y el café.

En la almendra el mesocarpio y el exocarpio forman la parte más blanda, correosa, del fruto; se conoce como cáscara o capote (en inglés: *hull*). El endocarpio (ver figura 2.1) es la cáscara dura, carozo o hueso (en inglés: *shell*). En la parte interna del carozo está la semilla (*kernel*) dicotiledónea, que es lo que vulgarmente se conoce como almendra. Esta se puede dividir longitudinalmente en dos mitades llamadas cotiledones. La semilla tiene una piel marrón que la rodea: el tegumento. Para diferenciar las partes de la semilla, llamaremos «carne» a la parte blanca que está dentro del tegumento.

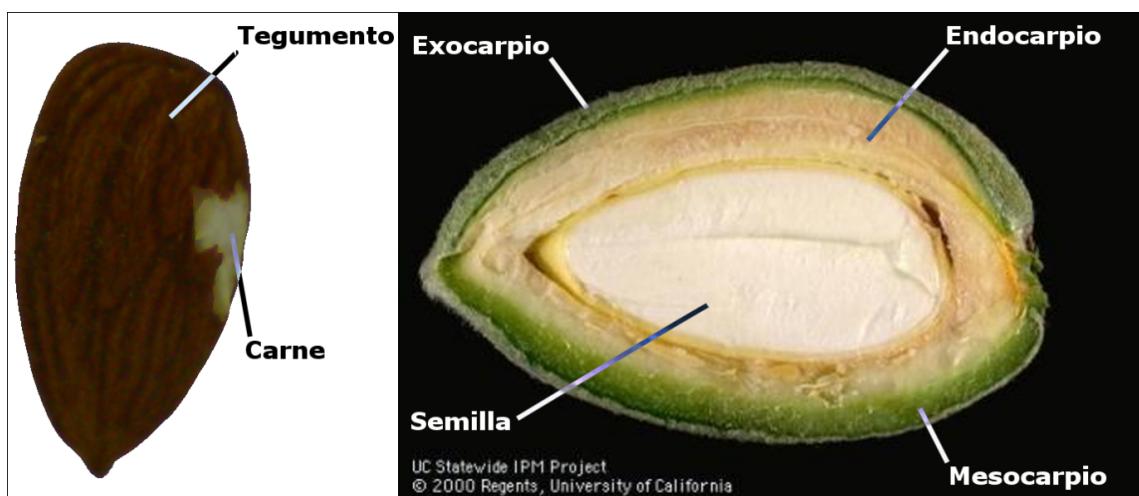


Figura 2.1: partes de una almendra. Izquierda: semilla; derecha: corte de un fruto completo. [6]

2.3 Normas

Existen normas que regulan el comercio de almendras peladas (sin cáscara). Hay tres normas que fueron útiles para definir los defectos a encontrar:

1. la Resolución 1352/1967 (capítulos XV y XIX) de la antigua Secretaría de Agricultura y Ganadería de la República Argentina, hoy bajo la órbita del Servicio Nacional de Sanidad y Calidad Agroalimentaria (SENASA); [7]
2. el «Estándar estadounidense para la calidad de almendras peladas», elaborado por el Departamento de Agricultura de ese país (USDA); [8]
3. el «Estándar DDP-06 acerca de la comercialización y control de calidad comercial de semillas de almendra», elaborado por la Comisión Económica de las Naciones Unidas para Europa (UNECE). [9]

Los tres documentos definen rasgos generales sobre los bienes a comercializar, y caracterizan defectos a encontrar, como «almendras partidas», «almendras dobles», «moho», «fragmento» y otros. Por último, establecen clases de calidad, cada una con distinta tolerancia a defectos o variaciones.

Las normas de UNECE y USDA son más explícitas a la hora de definir los defectos que la norma de SENASA. El Código Alimentario Argentino replica en su capítulo XI una versión abreviada de la Resolución 1352/1967. [10]

2.4 Soluciones existentes

Existen en el mercado máquinas capaces de resolver el problema con el mismo enfoque; se denominan máquinas de clasificación óptica o seleccionadoras ópticas (en inglés es común denominarlas como *optical sorting machines*, y no *optical classification machines*). Se utilizan, en general, luego de etapas de filtrado mecánico. Estas máquinas pueden usarse para una gran cantidad de frutos; el fabricante ajusta sus parámetros y añade o quita componentes según el fruto a clasificar y el presupuesto del comprador.

La estructura de la gran mayoría de ellas consiste de:

1. Una cinta transportadora o plataforma vibradora, que mueve los frutos.
2. Un tobogán o tubo que guía los frutos hacia un espacio de caída libre.
3. Una o más cámaras que capturan imágenes desde uno o ambos lados del objeto.
4. Eyectores que soplan los objetos malos.
5. Salidas de objetos malos y objetos buenos.

A modo de ejemplo, la figura 2.2 muestra un esquema de funcionamiento de una clasificadora Tomra Nimbus.

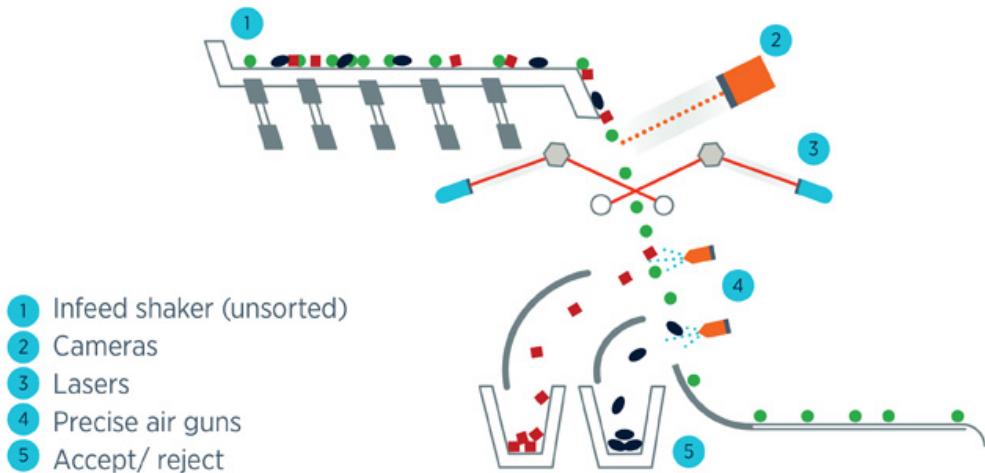


Figura 2.2: diagrama de funcionamiento de una máquina Tomra Nimbus. [11]

La figura 2.3 muestra la salida típica de una máquina clasificadora. Los defectos que pueden detectarse están determinados por el software de las máquinas y por el sistema de visión que tienen. Respecto a esto último, pueden tener cámaras e iluminadores en el espectro visible, en ultravioleta y en infrarrojo, que permiten detectar:

- Problemas de forma;
- Problemas de color;
- Hongos y toxinas superficiales;
- Objetos extraños.



Figura 2.3: salida de una máquina clasificadora comercial. De izquierda a derecha: almendras aceptadas; rechazadas por astilladas o raspadas; rechazadas por tamaño; rechazadas por ser cáscaras, almendras manchadas o podridas. [12]

La mayoría usa sensores CCD e iluminadores led, pero algunas incorporan luz láser y los sensores correspondientes, para analizar ciertos defectos.

Algunas empresas que fabrican estas máquinas son Tomra, Bühler, Cimbria y Key Technology; algunas de sus máquinas se muestran en la figura 2.4. Hay muchas más que fabrican máquinas simples que solo analizan el color. No se encontró información respecto a la precisión de las máquinas. Su capacidad depende del producto a analizar y los defectos a encontrar, pero es mayor a 0,5 toneladas/hora, pudiendo alcanzar 15 toneladas/hora.

En nuestro país, las máquinas de la familia Sortex de Bühler tienen un costo que oscila entre los 100 000 USD y los 300 000 USD —alrededor de 1 780 000 ARS y 5 340 000 ARS respectivamente, en agosto de 2017—, dependiendo de los defectos a remover y la capacidad de producción (entre 2 y 15 toneladas/hora). En función de esto varían el tipo y cantidad de cámaras (entre dos y veinte).¹



Figura 2.4: máquinas clasificadoras ópticas. De izquierda a derecha: Bühler Sortex A, Bühler Sortex E, Tomra Nimbus. [13, 14]

2.5 Propuesta

En este trabajo se quisieron abordar tres áreas específicas de la máquina: el software de clasificación, el proceso de captura y el sistema de desplazamiento de las almendras. Una vez comenzado el trabajo se hizo evidente que el sistema de visión artificial necesario no es independiente de los mecanismos de translación y eyección de objetos. Dado que estos últimos no están definidos todavía (y dependen de otras partes del proceso), adoptar un subsistema de visión único, sin considerar posibles limitaciones a las otras partes del sistema clasificador, es una decisión que probablemente implicaría problemas en futuras etapas. Es por esto que se decidió:

1. Hacer pruebas cortas de posibles sistemas de visión, lo más genéricos posibles.
2. Tomar el que mejor funcione (según algún criterio) y utilizarlo para generar un gran conjunto de imágenes.

Este conjunto de imágenes se usa para evaluar la efectividad que tienen diversos descriptores o predictores para clasificar los objetos que ingresen al sistema. Algunos de los descriptores usados son propuestos en la literatura revisada, mientras que otros surgen de nuestro análisis del problema de clasificación. Análogamente, se prueban diversas formas de identificar de forma única las posiciones y límites de los objetos en las imágenes —tarea conocida como segmentación—.

El conjunto de imágenes fue generado a partir de almendras y otros objetos provistos por un productor local. Se utilizaron (parcialmente) las normas de UNECE como verdad o patrón de referencia, para definir los defectos a buscar en las almendras y para comparar los resultados obtenidos. Algunos valores de referencia, como el color y el tamaño, se determinan a partir de la muestra ya que son características que varían naturalmente entre especies y cosechas.

¹Según comunicación por correo electrónico con Walter Tosco de Bühler Sortex Argentina (<http://sortex.com.ar>).

2.6 Herramientas y materiales

Se resumen a continuación algunas de las herramientas y materiales que se utilizaron en este trabajo. Se extenderá su descripción y forma de uso en secciones posteriores.

1. Cámara web Genius eFace 2050AF.
2. Muestras de almendras y otros objetos, provistos por el productor.
3. Matlab R2015b [15]. Se decidió hacer el desarrollo de los algoritmos en Matlab, ya que es una herramienta versátil; buena para la experimentación y el análisis; y de amplio uso en el Instituto de Automática (INAUT), donde probablemente se continúe el desarrollo del sistema.

Cajas de herramientas usadas:

- a) Image Processing Toolbox
- b) Computer Vision System Toolbox
- c) Image Acquisition Toolbox
- d) Statistics and Machine Learning Toolbox

Otros:

- a) Matlab Support Package for USB Webcams
- b) YAMLMatlab, para trabajar con archivos YAML de configuración de parámetros [16]
- c) MBeautifier, para uniformar el formato del código [17]
- d) multic (Confusion Matrix and its Derivations) [18]
- e) Balu Toolbox for Matlab [19]
4. GIMP 2.8.18: Programa de edición de imágenes utilizado como complemento a Matlab para el diseño de algoritmos y análisis de las imágenes disponibles. Se usó también el complemento GMIC 1.79 para el procesamiento. [20, 21]
5. KNIME 3.3.2: Programa de minería de datos usado para comparar resultados. [22]
6. Perfiles metálicos y accesorios; poliestireno de alto impacto; madera MDF; vidrios y espejos, para la construcción de un prototipo de estructura.
7. Tiras de leds, una fuente commutada y materiales eléctricos, para la construcción de luminarias.

3 Resultados

En base al desempeño observado durante el desarrollo y prueba de cada una de las etapas de preprocesamiento, segmentación y clasificación, elegimos algunas de ellas para formar parte del algoritmo a evaluar. El algoritmo es (ver figura 3.1):

1. Preprocesador: suavizado gaussiano
2. Segmentador: basado en imagen retroiluminada
3. Clasificador: según altura
4. Clasificador: según extensión de la caja envolvente
5. Clasificador: según relación de aspecto de los ejes de una elipse ajustada
6. Clasificador: según área sin tegumento (raspaduras) a partir de canales H, S y V
7. Clasificador: según media de color (canal H)
8. Clasificador: según desviación de color (canal H)
9. Clasificador: según media de color (canal a*)
10. Clasificador: según media de color (canal b*)
11. Clasificador: según solidez

Quedó fuera el clasificador según la relación de aspecto de la caja envolvente, porque es muy similar al de la relación de aspecto de la elipse ajustada. No se usó el clasificador según el área de arrugas por su mal desempeño general. El clasificador según área de raspaduras a partir de los canales H, S y V es mejor que el que solo usa S.

Es importante notar que los clasificadores según características de color (etapas 7, 8, 9 y 10) realizan sus medidas a partir de los datos que están en las zonas con tegumento¹; esta está determinada por la máscara creada por el clasificador según raspaduras y por tanto las medidas solo serán correctas en el caso de almendras y objetos de colores similares a los de las almendras.

Los parámetros de funcionamiento de cada clasificador fueron ajustados heurísticamente durante su desarrollo², analizando su desempeño general o específico para el defecto que buscaban encontrar. Los parámetros que determinan los límites de clasificación se ajustarán según diferentes estrategias, como se menciona más adelante.

¹También se pueden usar con la máscara del objeto completo.

²Los valores se pueden ver en los archivos de clase correspondientes o en cualquier archivo `parametros_efectivos*.yml` en las carpetas de experimentos.

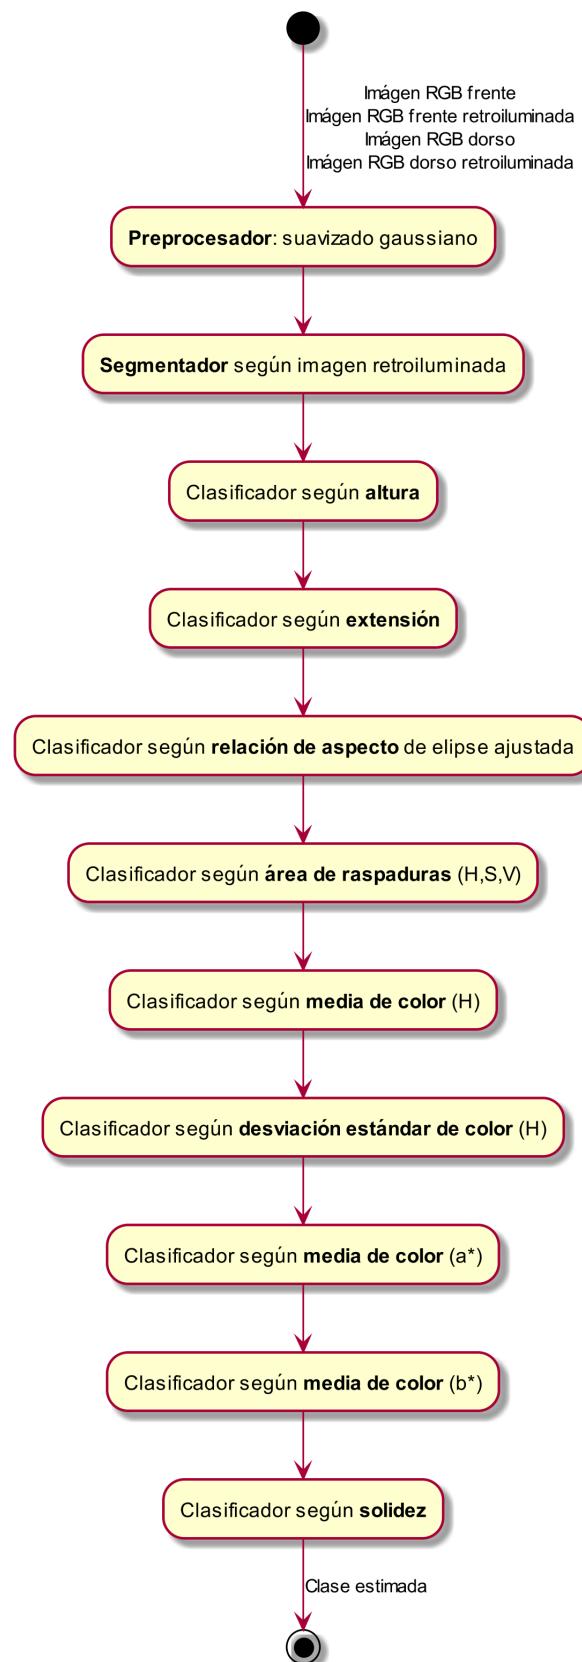


Figura 3.1: etapas del algoritmo final.

3.1 Metodología de ajuste y evaluación

3.1.1 Evaluación

La evaluación se hará sobre el conjunto set3, para dos casos de trabajo distintos:

1. Contemplando las tres clases del conjunto: Primera, Mala y No Almendra.
2. Simplificando a solo dos clases: Buena (clase Primera) y Mala (clase Mala y clase No Almendra).
Esto se justifica porque no encontramos criterios confiables para separar las clases Mala y No Almendra.

La evaluación se hará sobre el conjunto de evaluación —un 20 % del total—, mientras que el ajuste de los parámetros de clasificación de cada etapa se hará según los valores de los descriptores sobre el conjunto de entrenamiento —el restante 80 %—. Ver ??.

Los resultados de nuestro clasificador serán contrastados contra los obtenidos por algoritmos de aprendizaje automático en KNIME y Matlab Classification Learner (ver 2.6) a partir de los mismos descriptores. De la herramienta de Matlab se usarán algunas de las configuraciones por defecto disponibles en la galería de clasificadores (usando validación cruzada con las mismas proporciones —80 % de entrenamiento y 20 % de validación— que usamos para dividir el conjunto set3):

- Un árbol de decisiones simple, con menos de cuatro particiones (*splits*)
- Un árbol de decisiones de tamaño medio, con menos de veinte particiones (*splits*)
- Una máquina de vector soporte o máquina de soporte vectorial (SVM) lineal
- Una SVM de núcleo cuadrático
- Una SVM de núcleo cúbico
- Un clasificador de k vecinos cercanos (*k-nearest neighbours*, KNN), con un vecino
- Un clasificador KNN con diez vecinos
- *Boosted Trees*: un arreglo de clasificadores (árboles de decisión) optimizados con el algoritmo Adaboost.

En KNIME dividimos el conjunto set3 en dos subconjuntos (80 % de entrenamiento y 20 % de validación) y probamos dos clasificadores, con las opciones por defecto:

- Un árbol de decisión con menos de diez particiones
- Un clasificador KNN con tres vecinos

3.1.2 Métrica

La métrica de evaluación de cada algoritmo será la exactitud global (*overall accuracy*) del sistema:

$$\text{Exactitud global} = \frac{\text{elementos clasificados correctamente}}{\text{total de elementos}} \quad (3.1)$$

Esta se puede usar tanto para el caso de clasificación multiclas (Primera, Mala y No Almendra) como para la simplificación binaria (Buena y Mala).

Para este último caso, las proporciones de Buena y Mala son muy similares y por tanto no existe error de (alta) exactitud causado por clases desproporcionadas. Dado esto, un clasificador binario aleatorio tendrá una exactitud igual a la proporción inicial de las clases, cercana al 50 %; por tanto 50 % es la base de referencia para la clasificación binaria.

3.1.3 Ajuste

Los parámetros de clasificación (máximos y mínimos tolerados) de cada etapa clasificadora fueron ajustados siguiendo distintas estrategias, en base a los valores de los descriptores calculados para las almendras clasificadas como de Primera clase dentro del conjunto de entrenamiento (ver tabla 3.1).

Las estrategias son:

Máximos y mínimos (Maxmin) Los máximos y mínimos de tolerancia para cada clasificador son los máximos y mínimos medidos en las almendras de Primera clase del conjunto de entrenamiento.

90 % Se supone que cada descriptor sigue una distribución normal, con media μ y desviación estándar σ ; la muestra es el conjunto almendras de Primera clase dentro del conjunto de entrenamiento. Se ajustan los máximos a $\mu + 1,64\sigma$ y los mínimos a $\mu - 1,64\sigma$, lo cual abarca el 90 % de los datos en una distribución normal.

95 % Análoga a la estrategia anterior, pero con un rango $[\mu - 2\sigma, \mu + 2\sigma]$, que abarca al 95 % de los datos en una distribución normal.

99 % Análoga a las anteriores, pero con un rango $[\mu - 2,6\sigma, \mu + 2,6\sigma]$, que abarca al 99 % de los datos en una distribución normal.

Heurística 1 (H1) Todos los límites igual a los de **95 %**, menos la tolerancia del área máxima de raspaduras; esta es la que determina la norma de UNECE: el área de un círculo de 3 mm de diámetro (aproximadamente 7 mm^2).

Heurística 2 (H2) Análoga a **Heurística 1** pero usando los límites de **99 %**.

Tabla 3.1: características de los valores de los descriptores para las almendras de clase Buena (Primera) del conjunto de entrenamiento.

Medidas	Descriptores								
	Altura [px]	Extensión [px ² /px ²]	Relación de aspecto [px/px]	Área de raspaduras [mm ²]	Media de H [°]	Desv. Est. de H [°]	Media a*	Media b*	Solidez [px ² /px ²]
máximo	583,50	0,774	0,643	6,81	34,48	10,48	17,48	30,72	0,9955
mínimo	428,50	0,727	0,444	0,00	21,53	3,52	5,13	6,47	0,9837
μ	510,14	0,750	0,553	0,46	27,85	4,94	12,37	21,13	0,9931
σ	32,62	0,011	0,029	1,25	2,29	0,78	1,78	5,00	0,0014
$\mu + 1,64\sigma$	563,64	0,767	0,600	2,52	31,60	6,21	15,30	29,33	0,9953
$\mu - 1,64\sigma$	456,64	0,732	0,505	-1,59	24,10	3,66	9,45	12,94	0,9908
$\mu + 2\sigma$	575,38	0,771	0,610	2,97	32,42	6,49	15,94	31,13	0,9958
$\mu - 2\sigma$	444,90	0,729	0,495	-2,04	23,28	3,38	8,81	11,14	0,9903
$\mu + 2,6\sigma$	594,95	0,777	0,628	3,72	33,79	6,96	17,01	34,13	0,9966
$\mu - 2,6\sigma$	425,32	0,722	0,477	-2,79	21,91	2,91	7,74	8,14	0,9895

3.2 Resultados

La tabla 3.2 muestra los resultados obtenidos para las distintas estrategias de ajuste de parámetros, sobre los conjuntos de entrenamiento y de evaluación; la tabla 3.3 muestra los resultados obtenidos con los otros clasificadores.

Tabla 3.2: resultados obtenidos con distintas estrategias de ajuste de parámetros.

Clasificador	Exactitud global [%]			
	Entrenamiento		Evaluación	
	Buena, Mala	Primera, Mala, No Almendra	Buena, Mala	Primera, Mala, No Almendra
Maxmin	94,9	80,8	92,9	82,7
90 %	78,5	66,7	75,0	64,9
95 %	86,9	73,2	84,8	74,4
99 %	93,4	78,8	91,1	79,8
H1	89,2	74,6	86,6	75,6
H2	94,9	79,8	92,9	81,0

Hay una brecha de más de 10 % entre los resultados obtenidos considerando tres clases (Primera, Mala y No Almendra) y los obtenidos para el caso simplificado de dos clases (Buena y Mala). Esto era esperable, ya que nuestras etapas trabajan de forma independiente, y cada clasificador distingue entre dos clases solamente.

Los peores resultados son los de la estrategia **90 %**. Esto da un indicio de que (en general y suponiendo distribuciones normales) es pequeña la intersección entre los conjuntos de valores

Tabla 3.3: resultados obtenidos con otros clasificadores.

		Exactitud global [%]		
	Clasificador	Buena, Mala	Primera, Mala, No Almendra	
Matlab	Árbol simple	91,5		82,4
	Árbol medio	94,1		89,1
	SVM lineal	90,2		88,5
	SVM cuadrática	91,1		90,4
	SVM cúbica	93,1		92,2
	KNN 1 vecino	93,8		89,7
	KNN 10 vecinos	89,2		86,5
Classification Learner	Boosted Trees	94,5		91,5
	KNN 3 vecinos	94,7		90,3
	Árbol medio	92		92,9
KNIME				

correspondientes a Buenas y Malas. Dicho de otra manera, los descriptores elegidos tienen un buen poder de discriminación.

Nuestros mejores resultados corresponden a las estrategia **H2** y **Maxmin**, con una exactitud de 92,9 % para el caso de dos clases. Las tablas 3.4a y 3.4b muestran sus matrices de confusión para el conjunto de evaluación. Una distribución similar se observó sobre los conjuntos de entrenamiento, con **H2** teniendo menos Malas clasificadas como Buenas pero más Buenas clasificadas como Malas.

Tablas 3.4: matrices de confusión para el caso de dos clases, en el conjunto de evaluación.

		Clase estimada				Clase estimada	
		Buena	Mala			Buena	Mala
Clase real	Buena	50	5	Clase real		48	7
	Mala	3	54			1	56

Las Malas que se clasificaron como Buenas estaban clasificadas como Malas por tener mal color y estar arrugadas; por estar sucias; y por estar raspadas y astilladas, respectivamente.

Las Buenas que se clasificaron como Malas fueron rechazadas por su media de color (H y CIEL*a*b*), extensión, solidez o relación de aspecto.

Los resultados de contraste obtenidos en KNIME y Matlab Classification Learner tienen una brecha menor entre el caso de tres clases y el caso simplificado a dos clases; además, las exactitudes de las clasificaciones multiclas son mayores a las logradas con nuestro clasificador. Esto es entendible porque todos los otros clasificadores probados contemplan relaciones complejas entre los descriptores, en lugar de hacer un análisis independiente para cada descriptor.

La diferencia entre las mejores estrategias de ajuste (**H2** y **Maxmin** con 92,9 % sobre el conjunto de validación) y los mejores clasificadores externos es menor a 2 %. Asumiendo que los clasificadores

más potentes (como *Boosted Trees*) son aptos para ser aplicados a este problema y que deberían obtener los resultados máximos posibles, podemos decir que:

- nuestra estrategia de clasificación es buena, ya que alcanza exactitudes cercanas a las de otros clasificadores más complejos;
- los descriptores elegidos pueden ser insuficientes para lograr una clasificación con una exactitud del 100 %;
- la verdad de referencia (la clasificación manual del conjunto) puede tener errores que impiden una clasificación con una exactitud del 100 %.

Referencias

- [1] Luis Iannamico. *Cultivo del almendro*. Ed. por Ediciones INTA. 2015 (Citado en páginas 4, 7)
- [2] NCSS, LLC. *NCSS 11 Statistical Software (User Manual)*. Kaysville, Utah, USA, 2016. Cap. 230: Circular Data Analysis. URL: <https://www.ncss.com/software/ncss/ncss-documentation/#DescriptiveStatistics> (Citado en página 4)
- [3] Luis Iannamico. «Frutos secos: evolución del mercado internacional y situación argentina». En: *Suplemento El Rural del Diario Río Negro* (abr. de 2015). URL: <http://inta.gob.ar/documentos/frutos-secos-evolucion-del-mercado-internacional-y-situacion-argentina> (Citado en página 7)
- [4] FAOSTAT, División de Estadística de la Organización de las Naciones Unidas para la Alimentación y la Agricultura. *Matriz detallada del comercio de almendras peladas*. <http://www.fao.org/faostat/es/#search/almendras>. [Internet; visitado en junio de 2017] (Citado en página 7)
- [5] Humberto Secchi y Francisco Rossomando. *Diseño e implementación de una estrategia de clasificación óptica de almendras para pequeños productores*. PTDS N° 80020150600004SJ. 2016 (Citado en página 8)
- [7] Secretaría de Agricultura y Ganadería de la República Argentina. *Resolución 1352*. Buenos Aires, 14 de nov. de 1967. URL: <http://servicios.infoleg.gob.ar/infolegInternet/anexos/155000-159999/157438/norma.htm> (Citado en página 9)
- [8] United States Department of Agriculture. *United States Standards for Grades of Shelled Almonds*. Mar. de 1997 (Citado en página 9)
- [9] United Nations. *UNECE standard DDP-06 concerning the marketing and commercial quality control of almond kernels*. New York y Geneva, 2003 (Citado en página 9)
- [10] *Código alimentario argentino. Capítulo XI: alimentos vegetales*. Artículo 895 - (Resolución Conjunta SPReI N° 169/2013 y SAGyP N° 230/2013) (Citado en página 9)
- [23] Juan Pablo Graffigna Vaggione. «Detección de defectos de superficie mediante técnicas de Visión Artificial: aplicación a la selección de aceitunas». Trabajo Final. San Juan, Argentina: Universidad Nacional de San Juan, 1996

Programas

- [15] The Mathworks Inc. *Matlab*. Ver. R2015b. 20 de ago. de 2015. URL: <https://www.mathworks.com/products/matlab.html> (Citado en página 12)
- [16] Jiri Cigler y col. *YAMLMatlab*. Commit 20d3e1f. 2017. URL: <https://github.com/aguadopd/yamlmatlab> (Citado en página 12)

- [17] David Varga. *MBeautifier*. Ver. 1.2.1. 18 de nov. de 2016. URL: <https://github.com/davidvarga/MBeautifier> (Citado en página 12)
- [18] Eduard Polityko. *Confusion Matrix and its Derivations*. Ver. 1.0. 1 de mar. de 2017. URL: <https://www.mathworks.com/matlabcentral/fileexchange/61817-confusion-matrix-and-its-derivations> (Citado en página 12)
- [19] Domingo Mery. *BALU: A Matlab toolbox for computer vision, pattern recognition and image processing*. Ver. 4.0.1. 22 de mar. de 2016. URL: <http://dmery.ing.puc.cl/index.php/balu> (Citado en página 12)
- [20] The GIMP team. *GIMP*. Ver. 2.8.18. 16 de jul. de 2016. URL: <https://www.gimp.org> (Citado en página 12)
- [21] David Tschumperlé y GREYC UMR CNRS 6072, Image Team. *G'MIC (plug-in for GIMP)*. Ver. 1.7.8. 18 de nov. de 2016. URL: <http://gmic.eu> (Citado en página 12)
- [22] KNIME GmbH. *KNIME Analytics Platform*. Ver. 3.3.2. 6 de abr. de 2017. URL: <https://www.knime.org> (Citado en página 12)

Créditos de imágenes

- [6] Jack Kelly Clark. *Cross section of an almost mature almond nut*. Ed. por University of California. <http://fruitsandnuts.ucdavis.edu/files/108928display.jpg>. 2000. URL: <http://fruitsandnuts.ucdavis.edu/pages/almond/> (Citado en página 8)
- [11] Tomra Sorting Food Americas. *Nimbus working principle*. URL: <https://www.tomra.com/en/solutions-and-products/sorting-solutions/food/sorting-equipment/nimbus/> (Citado en página 10)
- [12] Bühler AG. *Unblanched Almonds*. URL: <http://www.buhlergroup.com/global/en/process-technologies/optical-sorting/nut-sorting/almond-sorting.htm> (Citado en página 10)
- [13] Bühler Sortex Inc. *Nuts and Dried Fruit Optical Sorting (Brochure)*. 2015 (Citado en página 11)
- [14] Tomra Sorting Food Americas. *Nimbus Optical Sorter (Brochure)*. 2016 (Citado en página 11)

A Organización de los archivos

- /inicializar.m – Archivo de inicialización (ver anexo B).
- /tfinal_AGUADO.pdf – Este documento.
- /clases/ – Archivos de clase de preprocesadores, segmentadores, clasificadores, clases principales, enumeraciones y otros.
- /experimentos/ – Archivos de cada experimento realizado. Cada carpeta contiene los archivos de configuración del experimento y planillas con los resultados generados.
- /funciones/ – Funciones principales y auxiliares desarrolladas en Matlab.
- /GUI/ – Interfaz gráfica de usuario.
- /imagenes/ – Los conjuntos de imágenes generados y sus metadatos. set1 sirvió para experimentación inicial, con set2 se desarrollaron los primeros algoritmos y set3 es el conjunto principal con el que se evaluó el sistema (ver sección ??). De este último se incluyen versiones preprocesadas —recortadas, sin distorsión y con máscaras binarias—. Los archivos .csv son las listas completas de imágenes y de los conjuntos de entrenamiento y evaluación; la planilla .xlsx tiene información sobre la clasificación manual.
- /info/ – Documentos e imágenes que fueron útiles para la realización de este trabajo.
- /otros/ – Archivos correspondientes a programas de terceros requeridos o utilizados: Balu, YAMLMatlab y multic.
- /scripts/ – Programas auxiliares usados durante el trabajo. No son necesarios para la ejecución de experimentos; sirvan para referencia futura.

B Uso de los programas

Los programas requieren que se definan las variables `carpeta_base` y `carpeta_imagenes` con las rutas **absolutas** a la carpeta raíz de los programas (raíz de las carpetas `GUI`, `clases`, ...) y a la carpeta raíz de las imágenes respectivamente (raíz de las carpetas `set1`, `set2`, `set3`, ...).

Para ello, como requisito inicial, se debe editar el archivo `inicializar.m`, disponible en el directorio raíz.

Si bien se pueden editar y ejecutar los experimentos disponibles en la carpeta `/experimentos/`, recomiendo ejecutar la interfaz gráfica de usuario para poder apreciar lo que están haciendo los programas. Para ello:

1. Editar y ejecutar `inicializar.m`.
2. Editar `/GUI/gui.m` y seleccionar (comentando y descomentando líneas) el conjunto de imágenes a utilizar y las etapas del algoritmo.
3. Ejecutar `gui.m`.